Contexto

Uma empresa do ramo de e-commerce solicitou um levantamento sobre os indicadores de recência, frequência e ticket médio (RFM) dos seus clientes.

A saber RFM:

- R (Recency): Tempo que o cliente realizou a última compra (em dias)
- F (Frequency): Quantidade de compras realizadas pelo cliente
- M (Monetary): Valor do ticket médio gasto pelo cliente

Ticket médio = média do total gasto por pedido para cada cliente.

Para isso,a empresa disponiblizou uma base de dados (arquivo csv). Inicialmente, foi identificado o Python como ferramenta de utilização, gerando um output seguro e satisfatório para o cliente. Para a segurança da empresa, o arquivo será nomeado contendo apenas a identificação do cliente e métricas RFM.

Sobre os dados

A tabela contém informações de compras de um e-commerce em 37 países. Contém a identificação do cliente e os dados da compra.

Coluna	Descrição
CustomerID	Código de identificação do cliente
Description	Descrição do produto
InvoiceNo	Código da fatura
StockCode	Código de estoque do produto
Quantity	Quantidade do produto
InvoiceDate	Data do faturamento (compra)
UnitPrice	Preço unitário do produto
Country	País da compra

Como começar?

1. Importar o dataset para o colab
2. Entender os dados
3. Tratar os dados nulos
4. Tratar os outliers

Dessa forma, vamos desenvolver o algoritmo para receber o arquivo csv de entrada e retornar um algoritmo de saída com as seguintes colunas:

- **CustomerID: Código do cliente**
- **R: Recência**
- **F: Frequência**
- **M: Ticket médio**

1 - Análise Descritiva

1.1 - Upload do arquivo (desafio_5.csv)

```
from google.colab import files
uploaded = files.upload()
```

```
Escolher arquivos desafio_5.csv
• desafio_5.csv(text/csv) - 45580638 bytes, last modified: 24/11/2024 - 100% done
Saving desafio_5.csv to desafio_5.csv
```

1.2 - Importar bibliotecas

```
import pandas as pd

```

1.3 - Análise do DataFrame (df)

```
# O df = pd.read_csv não está funcionando

```

```
df = pd.read_csv("desafio_5.csv", encoding="latin1")  # Codificação mais comum para caracteres especiais
# ou
df = pd.read_csv("desafio_5.csv", encoding="ISO-8859-1")
# ou
df = pd.read_csv("desafio_5.csv", encoding="cp1252")
```

```
df.head()
```

	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
0	536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6	12/1/2010 8:26	2.55	17850.0	United Kingdom
1	536365	71053	WHITE METAL LANTERN	6	12/1/2010 8:26	3.39	17850.0	United Kingdom
2	536365	84406B	CREAM CUPID HEARTS COAT HANGER	8	12/1/2010 8:26	2.75	17850.0	United Kingdom

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 541909 entries, 0 to 541908
Data columns (total 8 columns):
 #   Column       Non-Null Count   Dtype
---  ------       --------------   -----
 0   InvoiceNo    541909 non-null  object
 1   StockCode    541909 non-null  object
 2   Description  540455 non-null  object
 3   Quantity     541909 non-null  int64
 4   InvoiceDate  541909 non-null  object
 5   UnitPrice    541909 non-null  float64
 6   CustomerID   406829 non-null  float64
 7   Country      541909 non-null  object
dtypes: float64(2), int64(1), object(5)
memory usage: 33.1+ MB
```

```
# InvoiceNo - object / str
# StockCode - object / str
# Description - object / str
# Quantity - int
# InvoiceDate - datetime
# UnitPrice - float
# CustomerID - int
# Country - object / str


df['InvoiceDate'] = pd.to_datetime(df['InvoiceDate'], format='%m/%d/%Y %H:%M') # datetime64[ns]

df = df.dropna(subset=['CustomerID'])
df['CustomerID'] = df['CustomerID'].astype(int)
# int

df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 406829 entries, 0 to 541908
Data columns (total 8 columns):
 #   Column       Non-Null Count   Dtype
---  ------       --------------   -----
 0   InvoiceNo    406829 non-null  object
 1   StockCode    406829 non-null  object
 2   Description  406829 non-null  object
 3   Quantity     406829 non-null  int64
 4   InvoiceDate  406829 non-null  datetime64[ns]
 5   UnitPrice    406829 non-null  float64
 6   CustomerID   406829 non-null  int64
 7   Country      406829 non-null  object
dtypes: datetime64[ns](1), float64(1), int64(2), object(4)
memory usage: 27.9+ MB
<ipython-input-6-73dc9b945281>:14: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus
  df['CustomerID'] = df['CustomerID'].astype(int)
```

```
df.describe()
```

	Quantity	InvoiceDate	UnitPrice	CustomerID
count	406829.000000	406829	406829.000000	406829.000000
mean	12.061303	2011-07-10 16:30:57.879207424	3.460471	15287.690570
min	-80995.000000	2010-12-01 08:26:00	0.000000	12346.000000
25%	2.000000	2011-04-06 15:02:00	1.250000	13953.000000
50%	5.000000	2011-07-31 11:48:00	1.950000	15152.000000
75%	12.000000	2011-10-20 13:06:00	3.750000	16791.000000
max	80995.000000	2011-12-09 12:50:00	38970.000000	18287.000000
std	248.693370	NaN	69.315162	1713.600303

Os valores negativos nas colunas 'Quantity' e 'UnitPrice' possuem chances consideráveis de existirem valores com erro de inserção, e/ou possíveis transações que precisam ser melhor aprofundadas, ex.: devoluções, etc. Além disso, as colunas estão com alta dispersão na maioria delas, indicando alta variabilidade dos dados.

```
neg_quantity = df[df['Quantity'] < 0]
print(neg_quantity)
```

```
       InvoiceNo StockCode                      Description  Quantity  \
141      C536379         D                         Discount        -1
154      C536383    35004C   SET OF 3 COLOURED  FLYING DUCKS        -1
235      C536391     22556    PLASTERS IN TIN CIRCUS PARADE        -12
236      C536391     21984  PACK OF 12 PINK PAISLEY TISSUES        -24
237      C536391     21983  PACK OF 12 BLUE PAISLEY TISSUES        -24
...          ...       ...                               ...       ...
540449   C581490     23144   ZINC T-LIGHT HOLDER STARS SMALL       -11
541541   C581499         M                           Manual        -1
541715   C581568     21258       VICTORIAN SEWING BOX LARGE        -5
541716   C581569     84978  HANGING HEART JAR T-LIGHT HOLDER        -1
541717   C581569     20979     36 PENCILS TUBE RED RETROSPOT        -5

               InvoiceDate  UnitPrice  CustomerID         Country
141    2010-12-01 09:41:00      27.50       14527  United Kingdom
154    2010-12-01 09:49:00       4.65       15311  United Kingdom
235    2010-12-01 10:24:00       1.65       17548  United Kingdom
236    2010-12-01 10:24:00       0.29       17548  United Kingdom
237    2010-12-01 10:24:00       0.29       17548  United Kingdom
...                    ...        ...         ...             ...
540449 2011-12-09 09:57:00       0.83       14397  United Kingdom
541541 2011-12-09 10:28:00     224.69       15498  United Kingdom
541715 2011-12-09 11:57:00      10.95       15311  United Kingdom
541716 2011-12-09 11:58:00       1.25       17315  United Kingdom
541717 2011-12-09 11:58:00       1.25       17315  United Kingdom

[8905 rows x 8 columns]
```

```
# Contagem de valores negativos
qt_neg_quantity = (df['Quantity'] <= 0).sum()
qt_neg_unitprice = (df['UnitPrice'] <= 0).sum()

print(f"Quantidade de valores negativos em 'Quantity': {qt_neg_quantity}")
print(f"Quantidade de valores negativos em 'UnitPrice': {qt_neg_unitprice}")

```

```
Quantidade de valores negativos em 'Quantity': 8905
Quantidade de valores negativos em 'UnitPrice': 40
```

```
# Valores nulos por coluna

print(df.isnull().sum())
```

```
InvoiceNo      0
StockCode      0
Description    0
Quantity       0
InvoiceDate    0
UnitPrice      0
CustomerID     0
Country        0
dtype: int64
```

Grande quantidade de valores nulos, impossibilitando o tratamento dos dados para este caso, pois, na coleta, não foram evidenciadas tratativas de solução ou alternativas para os valores nulos em questão.

```
nulos_customerid = df[df['CustomerID'].isnull()]
print(f' Linhas nulas da coluna CustomerID:')
print(nulos_customerid)
```

```
 Linhas nulas da coluna CustomerID:
Empty DataFrame
Columns: [InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country]
Index: []
```

2 - Análise Exploratória

2.1 - Removendo dados nulos e afins

```
# Removendo os dados nulos das colunas: CustomerID e Description, sendo:

# Description      1454
# CustomerID     135080

df = df.dropna(subset=['CustomerID', 'Description'])
df.info()

```

```
<class 'pandas.core.frame.DataFrame'>
Index: 406829 entries, 0 to 541908
Data columns (total 8 columns):
 #   Column       Non-Null Count   Dtype
---  ------       --------------   -----
 0   InvoiceNo    406829 non-null  object
 1   StockCode    406829 non-null  object
 2   Description  406829 non-null  object
 3   Quantity     406829 non-null  int64
 4   InvoiceDate  406829 non-null  datetime64[ns]
 5   UnitPrice    406829 non-null  float64
 6   CustomerID   406829 non-null  int64
 7   Country      406829 non-null  object
dtypes: datetime64[ns](1), float64(1), int64(2), object(4)
memory usage: 27.9+ MB
```

```
# Confirmação da ausência de valores nulos e na - pós tratamento:
print(f'Quantidade de valores null (nulos):\n{df.isnull().sum()}')
print('\n')
print(f'Quantidade de valores na (não aplicáveis):\n{df.isna().sum()}')
```

```
Quantidade de valores null (nulos):
InvoiceNo      0
StockCode      0
Description    0
Quantity       0
InvoiceDate    0
UnitPrice      0
CustomerID     0
Country        0
dtype: int64


Quantidade de valores na (não aplicáveis):
InvoiceNo      0
StockCode      0
Description    0
Quantity       0
InvoiceDate    0
UnitPrice      0
CustomerID     0
Country        0
dtype: int64
```

2.2 - Filtrando valores

```
df_filter_quantity = df[df['Quantity'] <= 0]
print(df_filter_quantity)

# 8905 valores menores ou iguais a zero, da coluna 'Quantity'
```

```
        InvoiceNo StockCode                       Description  Quantity  \
141      C536379         D                         Discount        -1
154      C536383    35004C   SET OF 3 COLOURED  FLYING DUCKS        -1
235      C536391     22556    PLASTERS IN TIN CIRCUS PARADE        -12
236      C536391     21984  PACK OF 12 PINK PAISLEY TISSUES        -24
237      C536391     21983  PACK OF 12 BLUE PAISLEY TISSUES        -24
...          ...       ...                               ...       ...
540449   C581490     23144   ZINC T-LIGHT HOLDER STARS SMALL       -11
541541   C581499         M                           Manual        -1
```

```
541715   C581568     21258        VICTORIAN SEWING BOX LARGE        -5
541716   C581569     84978  HANGING HEART JAR T-LIGHT HOLDER        -1
541717   C581569     20979     36 PENCILS TUBE RED RETROSPOT        -5

                InvoiceDate  UnitPrice  CustomerID         Country
141    2010-12-01 09:41:00      27.50       14527  United Kingdom
154    2010-12-01 09:49:00       4.65       15311  United Kingdom
235    2010-12-01 10:24:00       1.65       17548  United Kingdom
236    2010-12-01 10:24:00       0.29       17548  United Kingdom
237    2010-12-01 10:24:00       0.29       17548  United Kingdom
...                    ...        ...         ...             ...
540449 2011-12-09 09:57:00       0.83       14397  United Kingdom
541541 2011-12-09 10:28:00     224.69       15498  United Kingdom
541715 2011-12-09 11:57:00      10.95       15311  United Kingdom
541716 2011-12-09 11:58:00       1.25       17315  United Kingdom
541717 2011-12-09 11:58:00       1.25       17315  United Kingdom

[8905 rows x 8 columns]
```

```
df_filter_unitprice = df[df['UnitPrice'] <= 0]
print(df_filter_unitprice)

# 40 valores menores ou iguais a zero, da coluna 'UnitPrice'
```

```
139453    548318     22055   MINI CAKE STAND  HANGING STRAWBERY         5
145208    548871     22162          HEART GARLAND RUSTIC PADDED         2
157042    550188     22636   CHILDS BREAKFAST SET CIRCUS PARADE         1
187613    553000     47566                        PARTY BUNTING         4
198383    554037     22619            SET OF 6 SOLDIER SKITTLES        80
279324    561284     22167           OVAL WALL MIRROR DIAMANTE          1
282912    561669     22960             JAM MAKING SET WITH JARS        11
285657    561916         M                                Manual         1
298054    562973     23157           SET OF 6 NATIVITY MAGNETS        240
314745    564651     23270     SET OF 2 CERAMIC PAINTED HEARTS         96
314746    564651     23268  SET OF 2 CERAMIC CHRISTMAS REINDEER       192
314747    564651     22955             36 FOIL STAR CAKE CASES       144
314748    564651     21786                   POLKADOT RAIN HAT       144
358655    568158      PADS           PADS TO MATCH ALL CUSHIONS         1
361825    568384         M                                Manual         1
379913    569716     22778                   GLASS CLOCHE SMALL         2
395529    571035         M                                Manual         1
420404    572893     21208          PASTEL COLOUR HONEYCOMB FAN         5
436428    574138     23234         BISCUIT TIN VINTAGE CHRISTMAS       216
436597    574175     22065       CHRISTMAS PUDDING TRINKET POT         12
436961    574252         M                                Manual         1
439361    574469     22385            JUMBO BAG SPACEBOY DESIGN        12
446125    574879     22625                   RED KITCHEN SCALES         2
446793    574920     22899         CHILDREN'S APRON DOLLY GIRL          1
446794    574920     23480       MINI LIGHTS WOODLAND MUSHROOMS         1
454463    575579     22437        SET OF 9 BLACK SKULL BALLOONS        20
454464    575579     22089        PAPER BUNTING VINTAGE PAISLEY        24
479079    577129     22464          HANGING METAL HEART LANTERN         4
479546    577168         M                                Manual         1
480649    577314     23407       SET OF 2 TRAYS HOME SWEET HOME         2
485985    577696         M                                Manual         1
502122    578841     84826       ASSTD DESIGN 3D PAPER STICKERS     12540

                InvoiceDate  UnitPrice  CustomerID         Country
9302   2010-12-05 14:02:00        0.0       12647         Germany
33576  2010-12-16 14:36:00        0.0       16560  United Kingdom
40089  2010-12-21 13:45:00        0.0       14911            EIRE
47068  2011-01-06 16:41:00        0.0       13081  United Kingdom
47070  2011-01-06 16:41:00        0.0       13081  United Kingdom
56674  2011-01-13 15:10:00        0.0       15107  United Kingdom
86789  2011-02-10 13:08:00        0.0       17560  United Kingdom
130188 2011-03-23 10:25:00        0.0       13239  United Kingdom
139453 2011-03-30 12:45:00        0.0       13113  United Kingdom
145208 2011-04-04 14:42:00        0.0       14410  United Kingdom
157042 2011-04-14 18:57:00        0.0       12457     Switzerland
187613 2011-05-12 15:21:00        0.0       17667  United Kingdom
198383 2011-05-20 14:13:00        0.0       12415       Australia
279324 2011-07-26 12:24:00        0.0       16818  United Kingdom
282912 2011-07-28 17:09:00        0.0       12507           Spain
285657 2011-08-01 11:44:00        0.0       15581  United Kingdom
298054 2011-08-11 11:42:00        0.0       14911            EIRE
314745 2011-08-26 14:19:00        0.0       14646     Netherlands
314746 2011-08-26 14:19:00        0.0       14646     Netherlands
314747 2011-08-26 14:19:00        0.0       14646     Netherlands
314748 2011-08-26 14:19:00        0.0       14646     Netherlands
358655 2011-09-25 12:22:00        0.0       16133  United Kingdom
361825 2011-09-27 09:46:00        0.0       12748  United Kingdom
379913 2011-10-06 08:17:00        0.0       15804  United Kingdom
395529 2011-10-13 12:50:00        0.0       12446             RSA
```

```
df_filter_quantity.info() # 8905 valores menores ou iguais a zero
print('\n')
df_filter_unitprice.info() # 40 valores menores ou iguais a zero

# 8945 valores menores ou iguais a zero (total)
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 8905 entries, 141 to 541717
Data columns (total 8 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   InvoiceNo    8905 non-null   object
 1   StockCode    8905 non-null   object
 2   Description  8905 non-null   object
 3   Quantity     8905 non-null   int64
 4   InvoiceDate  8905 non-null   datetime64[ns]
 5   UnitPrice    8905 non-null   float64
 6   CustomerID   8905 non-null   int64
 7   Country      8905 non-null   object
dtypes: datetime64[ns](1), float64(1), int64(2), object(4)
memory usage: 626.1+ KB


<class 'pandas.core.frame.DataFrame'>
Index: 40 entries, 9302 to 502122
Data columns (total 8 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   InvoiceNo    40 non-null     object
 1   StockCode    40 non-null     object
 2   Description  40 non-null     object
 3   Quantity     40 non-null     int64
 4   InvoiceDate  40 non-null     datetime64[ns]
 5   UnitPrice    40 non-null     float64
 6   CustomerID   40 non-null     int64
 7   Country      40 non-null     object
dtypes: datetime64[ns](1), float64(1), int64(2), object(4)
memory usage: 2.8+ KB
```

```
# Filtro de ambas as colunas, com valores maiores que zero

df_filter_qt_price = df[(df['Quantity'] > 0) | (df['UnitPrice'] > 0)]
print(df_filter_qt_price)

```

```
        InvoiceNo StockCode                          Description  Quantity  \
0          536365    85123A   WHITE HANGING HEART T-LIGHT HOLDER         6
1          536365     71053                  WHITE METAL LANTERN         6
2          536365    84406B       CREAM CUPID HEARTS COAT HANGER         8
3          536365    84029G  KNITTED UNION FLAG HOT WATER BOTTLE         6
4          536365    84029E       RED WOOLLY HOTTIE WHITE HEART.         6
...           ...       ...                                  ...       ...
541904     581587     22613          PACK OF 20 SPACEBOY NAPKINS        12
541905     581587     22899         CHILDREN'S APRON DOLLY GIRL          6
541906     581587     23254        CHILDRENS CUTLERY DOLLY GIRL          4
541907     581587     23255      CHILDRENS CUTLERY CIRCUS PARADE         4
541908     581587     22138        BAKING SET 9 PIECE RETROSPOT          3

                InvoiceDate  UnitPrice  CustomerID         Country
0       2010-12-01 08:26:00       2.55       17850  United Kingdom
1       2010-12-01 08:26:00       3.39       17850  United Kingdom
2       2010-12-01 08:26:00       2.75       17850  United Kingdom
3       2010-12-01 08:26:00       3.39       17850  United Kingdom
4       2010-12-01 08:26:00       3.39       17850  United Kingdom
...                     ...        ...         ...             ...
541904 2011-12-09 12:50:00       0.85       12680          France
541905 2011-12-09 12:50:00       2.10       12680          France
541906 2011-12-09 12:50:00       4.15       12680          France
541907 2011-12-09 12:50:00       4.15       12680          France
541908 2011-12-09 12:50:00       4.95       12680          France

[406829 rows x 8 columns]
```

```
# 5225 valores duplicados

df_duplicated_removed = df_filter_qt_price[df_filter_qt_price.duplicated()]
print(df_duplicated_removed)
```

```
        InvoiceNo StockCode                          Description  Quantity  \
517        536409     21866        UNION JACK FLAG LUGGAGE TAG         1
527        536409     22866      HAND WARMER SCOTTY DOG DESIGN         1
537        536409     22900    SET 2 TEA TOWELS I LOVE LONDON          1
539        536409     22111       SCOTTIE DOG HOT WATER BOTTLE         1
555        536412     22327  ROUND SNACK BOXES SET OF 4 SKULLS         1
...           ...       ...                                  ...       ...
541675     581538     22068        BLACK PIRATE TREASURE CHEST         1
541689     581538     23318     BOX OF 6 MINI VINTAGE CRACKERS         1
541692     581538     22992             REVOLVER WOODEN RULER          1
541699     581538     22694                       WICKER STAR          1
541701     581538     23343       JUMBO BAG VINTAGE CHRISTMAS          1

                InvoiceDate  UnitPrice  CustomerID         Country
517     2010-12-01 11:45:00       1.25       17908  United Kingdom
527     2010-12-01 11:45:00       2.10       17908  United Kingdom
```

```
537    2010-12-01 11:45:00       2.95       17908  United Kingdom
539    2010-12-01 11:45:00       4.95       17908  United Kingdom
555    2010-12-01 11:49:00       2.95       17920  United Kingdom
...                    ...        ...         ...             ...
541675 2011-12-09 11:34:00       0.39       14446  United Kingdom
541689 2011-12-09 11:34:00       2.49       14446  United Kingdom
541692 2011-12-09 11:34:00       1.95       14446  United Kingdom
541699 2011-12-09 11:34:00       2.10       14446  United Kingdom
541701 2011-12-09 11:34:00       2.08       14446  United Kingdom

[5225 rows x 8 columns]
```

```
# DataFrame após a remoção dos valores duplicados

df_cleaned = df_filter_qt_price.drop_duplicates()
print(df_cleaned)
```

```
        InvoiceNo StockCode                          Description  Quantity  \
0          536365    85123A   WHITE HANGING HEART T-LIGHT HOLDER         6
1          536365     71053                  WHITE METAL LANTERN         6
2          536365    84406B       CREAM CUPID HEARTS COAT HANGER         8
3          536365    84029G  KNITTED UNION FLAG HOT WATER BOTTLE         6
4          536365    84029E       RED WOOLLY HOTTIE WHITE HEART.         6
...           ...       ...                                  ...       ...
541904     581587     22613          PACK OF 20 SPACEBOY NAPKINS        12
541905     581587     22899         CHILDREN'S APRON DOLLY GIRL          6
541906     581587     23254        CHILDRENS CUTLERY DOLLY GIRL          4
541907     581587     23255      CHILDRENS CUTLERY CIRCUS PARADE         4
541908     581587     22138        BAKING SET 9 PIECE RETROSPOT          3

                InvoiceDate  UnitPrice  CustomerID         Country
0       2010-12-01 08:26:00       2.55       17850  United Kingdom
1       2010-12-01 08:26:00       3.39       17850  United Kingdom
2       2010-12-01 08:26:00       2.75       17850  United Kingdom
3       2010-12-01 08:26:00       3.39       17850  United Kingdom
4       2010-12-01 08:26:00       3.39       17850  United Kingdom
...                     ...        ...         ...             ...
541904 2011-12-09 12:50:00       0.85       12680          France
541905 2011-12-09 12:50:00       2.10       12680          France
541906 2011-12-09 12:50:00       4.15       12680          France
541907 2011-12-09 12:50:00       4.15       12680          France
541908 2011-12-09 12:50:00       4.95       12680          France

[401604 rows x 8 columns]
```

```
# Remoção dos outliers extremos em que a quantidade do item na compra é superior a 10.000, e o preço unitário é maior que 5.000.

df_cleaned_filter = df_cleaned[(df_cleaned['Quantity'] <= 10000) & (df_cleaned['UnitPrice'] <= 5000)]
print(df_cleaned_filter)
print('\n')
df_cleaned_filter.info()

```

```
        InvoiceNo StockCode                          Description  Quantity  \
0          536365    85123A   WHITE HANGING HEART T-LIGHT HOLDER         6
1          536365     71053                  WHITE METAL LANTERN         6
2          536365    84406B       CREAM CUPID HEARTS COAT HANGER         8
3          536365    84029G  KNITTED UNION FLAG HOT WATER BOTTLE         6
4          536365    84029E       RED WOOLLY HOTTIE WHITE HEART.         6
...           ...       ...                                  ...       ...
541904     581587     22613          PACK OF 20 SPACEBOY NAPKINS        12
541905     581587     22899         CHILDREN'S APRON DOLLY GIRL          6
541906     581587     23254        CHILDRENS CUTLERY DOLLY GIRL          4
541907     581587     23255      CHILDRENS CUTLERY CIRCUS PARADE         4
541908     581587     22138        BAKING SET 9 PIECE RETROSPOT          3

                InvoiceDate  UnitPrice  CustomerID         Country
0       2010-12-01 08:26:00       2.55       17850  United Kingdom
1       2010-12-01 08:26:00       3.39       17850  United Kingdom
2       2010-12-01 08:26:00       2.75       17850  United Kingdom
3       2010-12-01 08:26:00       3.39       17850  United Kingdom
4       2010-12-01 08:26:00       3.39       17850  United Kingdom
...                     ...        ...         ...             ...
541904 2011-12-09 12:50:00       0.85       12680          France
541905 2011-12-09 12:50:00       2.10       12680          France
541906 2011-12-09 12:50:00       4.15       12680          France
541907 2011-12-09 12:50:00       4.15       12680          France
541908 2011-12-09 12:50:00       4.95       12680          France

[401597 rows x 8 columns]


<class 'pandas.core.frame.DataFrame'>
Index: 401597 entries, 0 to 541908
Data columns (total 8 columns):
 #   Column       Non-Null Count   Dtype
---  ------       --------------   -----
```

```
 0   InvoiceNo    401597 non-null  object
 1   StockCode    401597 non-null  object
 2   Description  401597 non-null  object
 3   Quantity     401597 non-null  int64
 4   InvoiceDate  401597 non-null  datetime64[ns]
 5   UnitPrice    401597 non-null  float64
 6   CustomerID   401597 non-null  int64
 7   Country      401597 non-null  object
dtypes: datetime64[ns](1), float64(1), int64(2), object(4)
memory usage: 27.6+ MB
```

3 - Modelagem

3.1 - Preparando os dados para análise mais avançadas

```
# Criação da coluna 'TotalPrice'

df_cleaned_filter['TotalPrice'] = df_cleaned_filter['Quantity'] * df_cleaned_filter['UnitPrice']

df_cleaned_filter = df_cleaned_filter[df_cleaned_filter['TotalPrice'] > 0]

df_cleaned_filter.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 392689 entries, 0 to 541908
Data columns (total 9 columns):
 #   Column       Non-Null Count   Dtype
---  ------       --------------   -----
 0   InvoiceNo    392689 non-null  object
 1   StockCode    392689 non-null  object
 2   Description  392689 non-null  object
 3   Quantity     392689 non-null  int64
 4   InvoiceDate  392689 non-null  datetime64[ns]
 5   UnitPrice    392689 non-null  float64
 6   CustomerID   392689 non-null  int64
 7   Country      392689 non-null  object
 8   TotalPrice   392689 non-null  float64
dtypes: datetime64[ns](1), float64(2), int64(2), object(4)
memory usage: 30.0+ MB
<ipython-input-21-95056d0e4a01>:3: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus
  df_cleaned_filter['TotalPrice'] = df_cleaned_filter['Quantity'] * df_cleaned_filter['UnitPrice']
```

```
# Data da última compra

data_primeira_compra = df_cleaned_filter['InvoiceDate'].min()
print(data_primeira_compra)

data_ultima_compra = df_cleaned_filter['InvoiceDate'].max()
print(data_ultima_compra)
```

```
2010-12-01 08:26:00
2011-12-09 12:50:00
```

3.2 - Plotando Gráficos

- Top 10 países com maior valor em vendas
- Top 10 produtos mais vendidos
- Valor de venda total por mês
- Valor de venda total por mês e por país (considere apenas os top 10)

3.2.1 - Bibliotecas de Análises Gráficas

```
import seaborn as sns
import matplotlib.pyplot as plt
import plotly.express as px
import altair as alt
import locale
```

```
top10_pais_vendas = df_cleaned_filter.groupby('Country')['TotalPrice'].sum().nlargest(10)

```

```
sns.barplot(x=top10_pais_vendas.values, y=top10_pais_vendas.index)
plt.xlabel('Total de Vendas')
plt.ylabel('País')
plt.title('Top 10 países com maior valor em vendas')
plt.show()
```

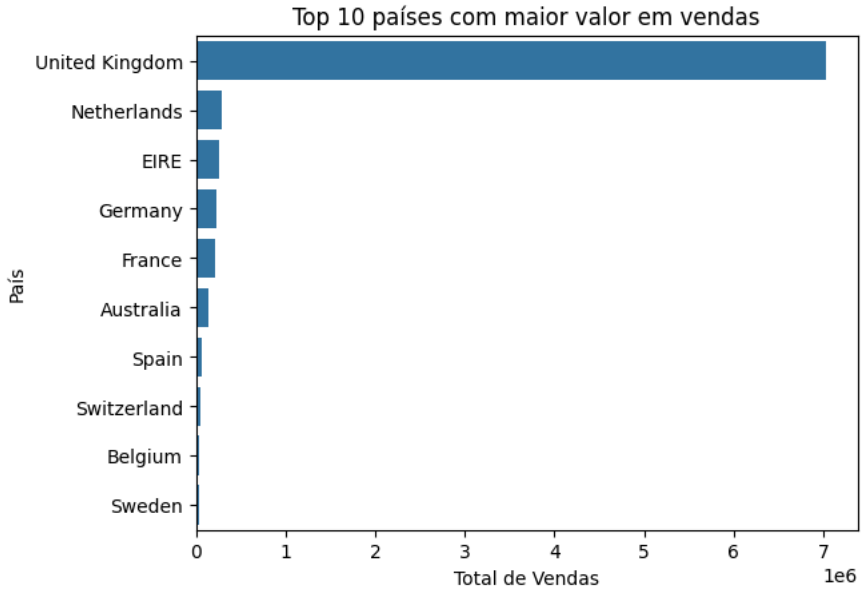


```
top10_produtos_vendas = df_cleaned_filter.groupby('Description')['Quantity'].sum().nlargest(10)

sns.barplot(x=top10_produtos_vendas.values, y=top10_produtos_vendas.index)
plt.xlabel('Quantidade de Vendas')
plt.ylabel('Produtos')
plt.title('Top 10 produtos mais vendidos')
plt.show()
```

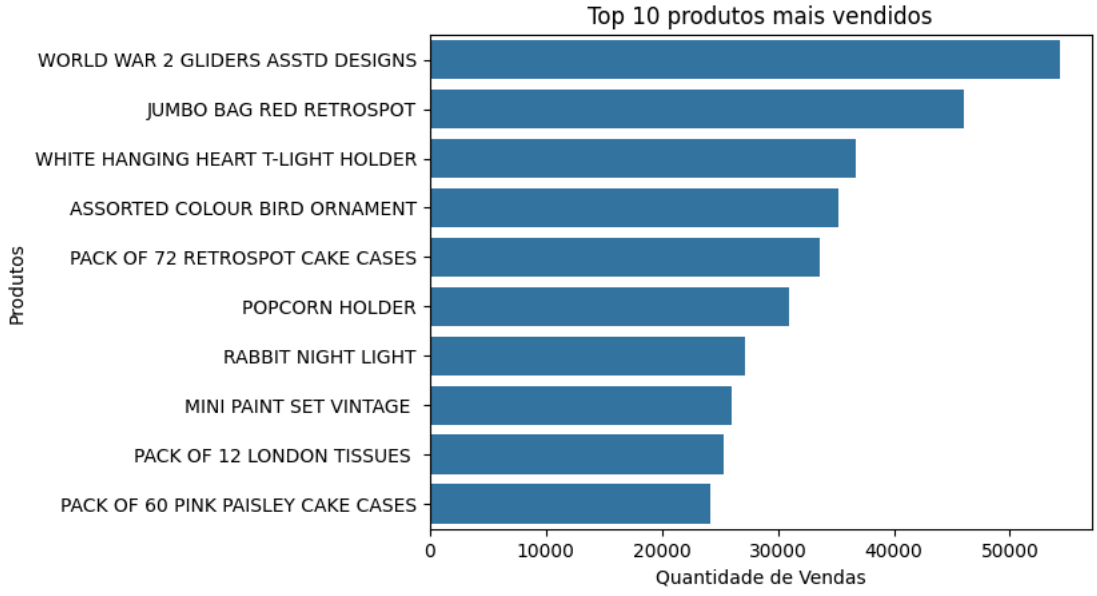


```
df_cleaned_filter['Month'] = df_cleaned_filter['InvoiceDate'].dt.strftime('%Y-%m')

# Faturamento/mês
sales_per_month = df_cleaned_filter.groupby('Month')['TotalPrice'].sum().reset_index()

sales_per_month = sales_per_month.sort_values('Month')

# Plotar gráfico
plt.figure(figsize=(10, 5))
sns.lineplot(x='Month', y='TotalPrice', data=sales_per_month, marker='o', linestyle='-')


plt.xticks(rotation=45)  # Rotacionar os meses para melhor leitura
plt.xlabel('Mês')
plt.ylabel('Faturamento Total')
plt.title('Faturamento por Mês')
plt.grid(True)

# 7. Exibir gráfico
```

```
plt.show()

```

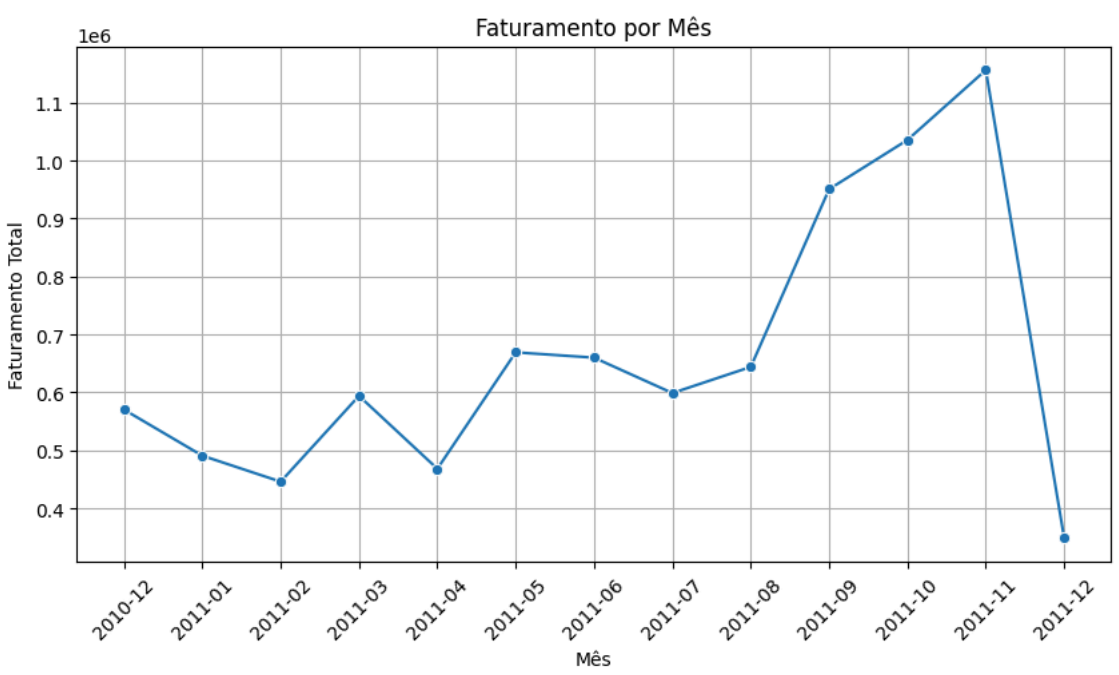


```
df_cleaned_filter['InvoiceDate'] = pd.to_datetime(df_cleaned_filter['InvoiceDate'])

df_cleaned_filter['Month'] = df_cleaned_filter['InvoiceDate'].dt.to_period('M')

total_sales_by_month_country = df_cleaned_filter.groupby(['Month', 'Country'])['TotalPrice'].sum().reset_index()

top_10_countries = total_sales_by_month_country.groupby('Country')['TotalPrice'].sum().nlargest(10).index

# Filtrar para considerar apenas os top 10 países
top_10_sales = total_sales_by_month_country[total_sales_by_month_country['Country'].isin(top_10_countries)]

# Criar gráfico
plt.figure(figsize=(12, 6))
for country in top_10_countries:
    country_data = top_10_sales[top_10_sales['Country'] == country]
    plt.plot(country_data['Month'].astype(str), country_data['TotalPrice'], label=country)

plt.xticks(rotation=45)
plt.xlabel('Mês')
plt.ylabel('Valor Total de Vendas')
plt.title('Valor Total de Vendas por Mês e País (Top 10)')
plt.legend(title='País')
plt.tight_layout()
plt.show()
```

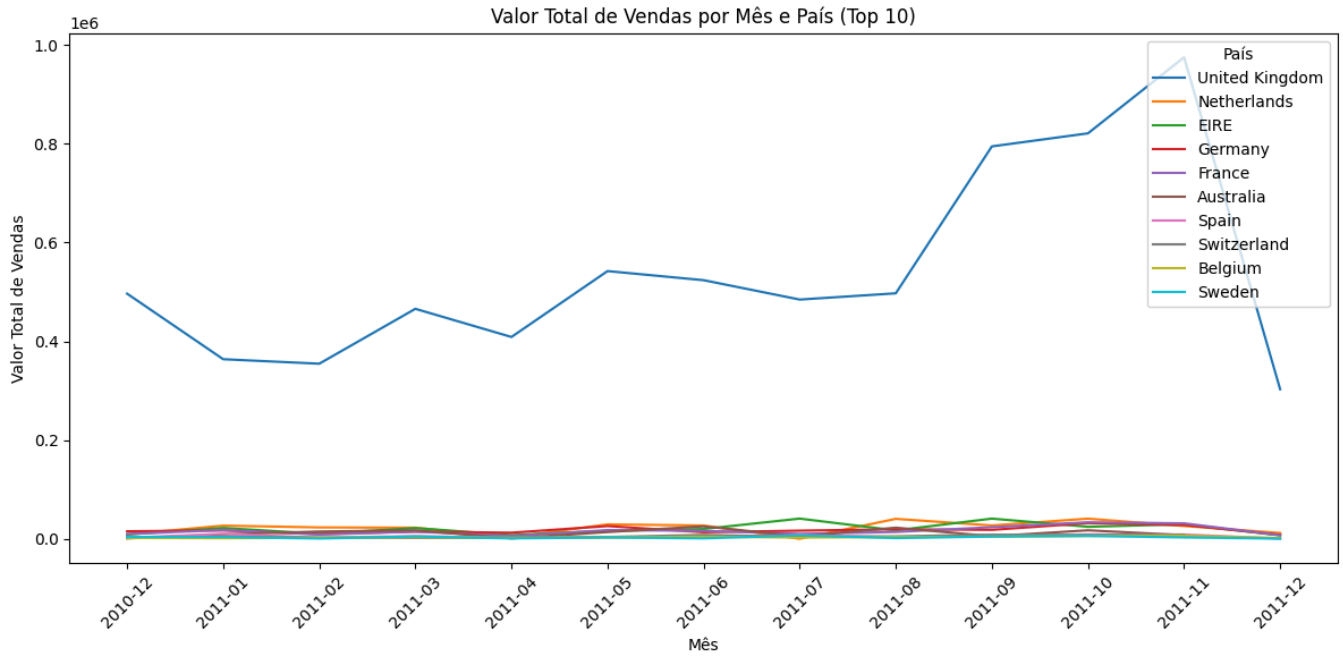

4 - Calculo da Predição

Recomendação: Dados por cliente e pedido/compra (InvoiceNo) e obtenha a data e o preço total do pedido. Ou seja, importante agrupar novamente apenas por cliente e calcular o RFM, onde:

- R é a recência, diferença em dias da última compra do cliente e da última compra disponível no conjunto de dados, que calcularam previamente.
- F é a frequência, ou seja, a quantidade de compras feitas pelo cliente;
- M é o ticket médio, ou seja, a média das compras feitas pelo cliente.

```
rfm = df_cleaned_filter.groupby('CustomerID').agg(
    Recency=('InvoiceDate', lambda x: (data_ultima_compra - x.max()).days),
    Frequency=('InvoiceNo', 'count'),
    Monetary=('TotalPrice', 'mean')
).reset_index()

rfm.describe()
```

	CustomerID	Recency	Frequency	Monetary
count	4337.000000	4337.000000	4337.000000	4337.000000
mean	15301.089232	91.529859	90.543924	37.645182
std	1721.422291	99.968030	225.528809	239.369697
min	12347.000000	0.000000	1.000000	1.450000
25%	13814.000000	17.000000	17.000000	12.381951
50%	15300.000000	50.000000	41.000000	17.745568
75%	16779.000000	141.000000	98.000000	24.861000
max	18287.000000	373.000000	7676.000000	13305.500000

4.1 - Explicação estatística dos dados obtidos

4.1.1 - Estatísticas Descritivas

count → O conjunto de dados possui 4.337 clientes únicos.

mean → Média dos valores de cada métrica:

Recência média: 91 dias (tempo médio desde a última compra).

Frequência média: 90 compras por cliente.

Ticket médio: R$ 37,65 por cliente.

std → A grande variação no Monetary (239,37) indica que há clientes com valores de compra muito diferentes.

4.1.2 - Mínimos e Quartis

Valores mínimos (clientes menos engajados):

Recência mínima: 0 dias (alguns clientes compraram na última data do dataset).

Frequência mínima: 1 (clientes que compraram apenas uma vez).

Monetary mínimo: R$ 1,45.

Distribuição por quartis:

25% (Q1): 25% dos clientes fizeram no máximo 17 compras e gastaram até R$ 12,38.

50% (Mediana): Metade dos clientes compraram até 41 vezes e gastaram até R$ 17,75.

75% (Q3): 75% dos clientes fizeram até 98 compras e gastaram até R$ 24,86.

4.1.3 - Valores Máximos (clientes VIPs)

Cliente mais ativo: Realizou 7.676 compras! 🏆

Maior valor gasto: R$ 13.305,50! 💰

4.2 - Planos de Ação (Conclusão)

4.2.1 - Distribuição Desbalanceada

Alguns clientes compram muito, enquanto outros compram pouco ou raramente.

✅ Soluções:

Criar estratégias personalizadas para cada segmento de clientes.

Implementar segmentação baseada no RFM para personalizar ofertas e comunicação.

Criar programas de fidelidade para incentivar compras mais frequentes.

Lançar campanhas de reativação para clientes que compram pouco, incluindo descontos exclusivos.

4.2.2 - Maximizar o Valor dos Clientes VIPs

Um pequeno grupo de clientes gera grande parte do faturamento.

✅ Soluções:

Fidelizar esse grupo com benefícios exclusivos.

Criar ofertas personalizadas baseadas no histórico de compras.

Implementar programas VIP com vantagens como frete grátis, cashback e atendimento prioritário.

4.2.3 - Aumentar o Ticket Médio

Muitos clientes fazem várias compras, mas gastam pouco por pedido.

✅ Soluções:

Criar descontos progressivos para incentivar compras maiores.

Oferecer pacotes de produtos (exemplo: "Leve 3, pague 2").

Implementar frete grátis acima de um determinado valor de compra.

4.2.4 - Reduzir Clientes com Baixa Frequência

Muitos clientes compram apenas uma vez e não retornam.

✅ Soluções:

Melhorar a experiência do cliente e o relacionamento pós-compra.

Enviar um e-mail de agradecimento e ofertas personalizadas após a primeira compra.